



使用说明

API 配置

1. 所用 API: <https://maas.xfyun.cn/modelSquare/base/2512021333487616?sort=0&inputValue=&userSelectCategoryList=&userSelectCategory=%255B%255D>



2. 将下方三个参数填入 `extract_papers.py` 的 13-15 行



代码运行

1. `pip install -r requirements.txt` 安装依赖
2. 终端输入 `python extract_papers.py`，出现提示后键入对应数字即可：

```
(planing) gnociew@WeicongdeMacBook-Air 3 % python extract_papers.py
请选择输入文件：
1. data/test.json (20篇测试)
2. data/arxiv_deduped_AI.json (AI分类)
3. data/arxiv_deduped_CL.json (CL分类)
4. data/arxiv_deduped_CV.json (CV分类)
5. data/arxiv_deduped_LG.json (LG分类)
请输入选择 (1-5, 默认1): 2
输出文件：
- 成功: extracted_papers_AI.jsonl
- 失败: failed_papers_AI.jsonl

正在读取 data/arxiv_deduped_AI.json...
共有 38720 篇论文待处理
警告：读取失败记录失败：Extra data: line 1 column 304 (char 303)
检测到已处理 94 篇，将跳过这些论文
```

如上图所示，以 AI 分类为例，成功处理的结果记录在 `extracted_papers_AI.jsonl` 中，而处理失败的文章记录在 `failed_papers_AI.jsonl` 中。

④ Note

已进行防中断处理，若运行中断只需**再次运行**上方的命令，程序会自动跳过两个输出文件中包含的数据。

3. 失败处理

- 可使用下方命令统计失败原因：`cat failed_papers_AI.jsonl | jq -r '.failure_reason' | sort | uniq -c`
- 若包含随机因素导致的失败（除解压失败、摘要为空的其它失败），运行 `python clean_failed_papers.py` 清除随机失败
- 再次运行提取代码进行尝试